

BASES DE DATOS 2

# TRANSACCIONES DISTRIBUIDAS

K E V I N M O R Á N B A S E S 2 . F I U S A C @ G M A I L . C O M



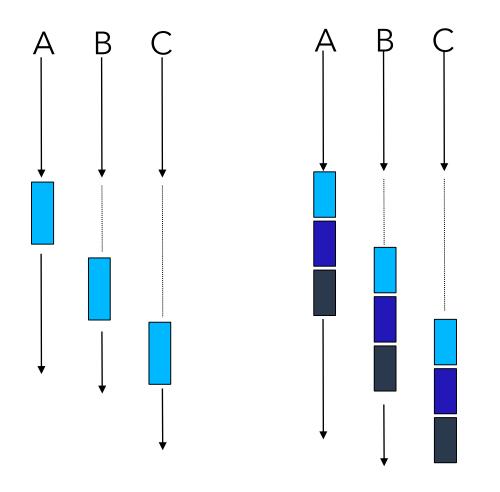
### CONTENIDO

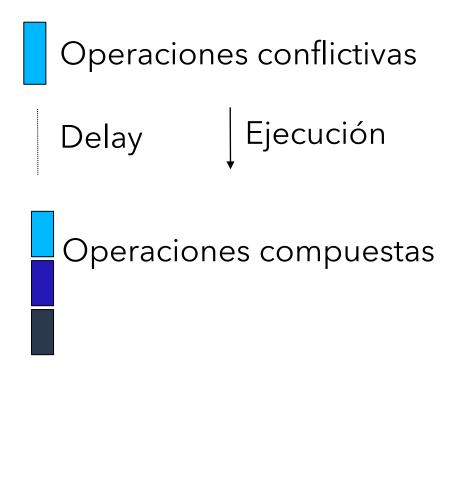
- Introducción y definiciones
- Algoritmos de compromiso
  - Two Phase Commit
  - Three Phase Commit
- Algoritmos de control de concurrencia
  - Por bloqueo (locking)
  - Optimista
  - Por marcas de tiempo (timestamp)
- Tratamientos de interbloqueos

# INTRODUCCIÓN Y DEFINICIONES

# TRANSACCIONES

Unidad de cálculo consistente, confiable y atómica





Serialización de operaciones conflictivas

# INTRODUCCIÓN Y DEFINICIONES

- Una transacción aplica a datos recuperables, puede estar formada por operaciones simples o compuestas y su intención es que sea atómica.
- Hay dos aspectos que se deben cumplir para lograr la atomicidad:
  - 1. Todo-o-nada: si una transacción termina exitosamente, los efectos de todas sus operaciones son registrados en los ítems de datos.
    - Si falla no tiene ningún efecto.

- La propiedad todo-o-nada también considera:
  - Atomicidad ante fallas: los efectos son atómicos aún cuando el servidor falla.
  - Durabilidad: después que una transacción ha terminado exitosamente, todos sus efectos son salvados en almacenamiento permanente.
- 2. Aislamiento: cada transacción debe ser ejecutada sin interferencias de otras transacciones, es decir, los resultados intermedios de una transacción no deben ser visibles a otras transacciones.
- Estas propiedades también son conocidas como propiedades ACID

# PROPIEDADES ACID

#### PROPIEDAD TODO-O-NADA

# **ATOMICIDAD**

- Para soportar la *atomicidad ante fallas* y la *durabilidad*, los ítems de datos deben ser recuperables.
- Hay dos tipos de fallas:
  - Transacción falla por si misma por errores en los datos de entrada, deadlocks, etc.
     Recuperación de la transacción.
  - Fallas por caídas del sistema, de los medios de E/S, de los procesadores, de las líneas de comunicación, fallas de energía, etc. Recuperación de caídas.

#### PROPIEDAD TODO-O-NADA

## ATOMICIDAD

- En la recuperación de caídas:
  - El sistema es quién tiene la responsabilidad de decidir qué hacer ante la recuperación de una falla:
  - Terminar de ejecutar el resto de las acciones.
  - Deshacer las acciones que se había realizado.
- Para proveer la recuperación se usan técnicas de almacenamiento estable.

UNA TRANSACCIÓN TOMA EL SISTEMA EN UN ESTADO CONSISTENTE Y LO DEJA EN UN ESTADO CONSISTENTE.

# CONSISTENCIA

IMPLICA SERIABILIDAD DE LAS TRANSACCIONES.

SE LES PERMITE A LAS TRANSACCIONES

EJECUTARSE CONCURRENTEMENTE SI SE OBTIENE

EL MISMO EFECTO DE UNA EJECUCIÓN

SECUENCIAL (SERIALMENTE EQUIVALENTES)

# **AISLAMIENTO**

# DURABILIDAD

# PRIMITIVAS SOBRE TRANSACCIONES

- begin\_transaction 

   tid: inicia una transacción y devuelve un identificador de la transacción
- close\_transaction(tid) → (Commit, Abort)
  - Commit: la transacción termina exitosamente y sus efectos van a almacenamiento permanente.
  - Abort: no se reflejan los cambios. Los abortos pueden ser causados por la propia naturaleza de la transacción, por conflictos con otras transacciones o por fallas.
- abort\_transaction(tid): aborto intencional.
- read y write: típicamente una transacción se compone de una serie de lecturas y escrituras y algunos cálculos.

# TRANSACCIONES ANIDADAS

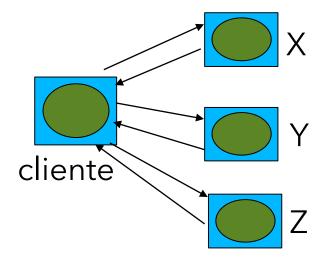
- Las transacciones pueden contener subtransacciones.
  - Problema: Si una transacción interna realiza commit y una más externa abort, se pierden las propiedades de atomicidad y aislamiento por cumplir con la durabilidad.
  - . Generalmente la durabilidad sólo se considera para la transacción más externa.
  - En algunaos sistemas, la transacción superior puede decidir hacer commit aún cuando alguna subtransacción aborta.

# IMPLEMENTACIÓN DE LAS TRANSACCIONES

- Espacio de trabajo privado:
  - . Se copian los datos en un espacio propio de cada transacción
  - . Al finalizar exitosamente la transacción se actualizan en la base de datos
- Lista de intención (writeahead log)
  - Las actualizaciones son realizadas directamente en la base de datos
  - . Se lleva un registro de los cambios realizados

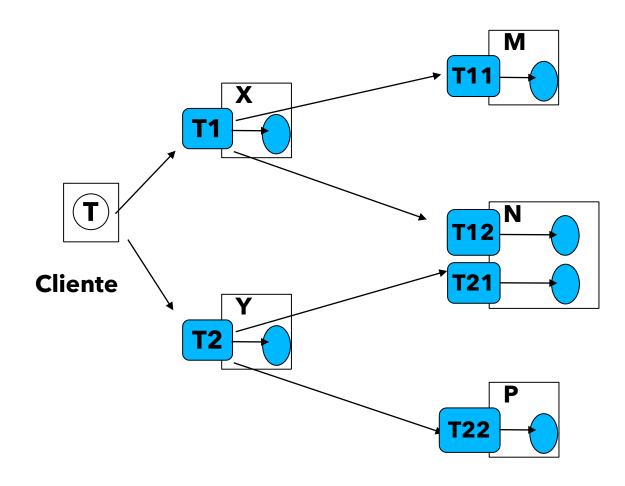
# TRANSACCIONES DISTRIBUIDAS

- Sus actividades envuelven múltiples servidores.
- Los ítems de datos de un servidor pueden estar distribuidos entre varios servidores y, en general, una transacción de un cliente puede envolver múltiples servidores.
- Las transacciones distribuidas pueden ser simples o anidadas.



# Cliente: begin\_transaction call X.x call Y.y call Z.z end transaction

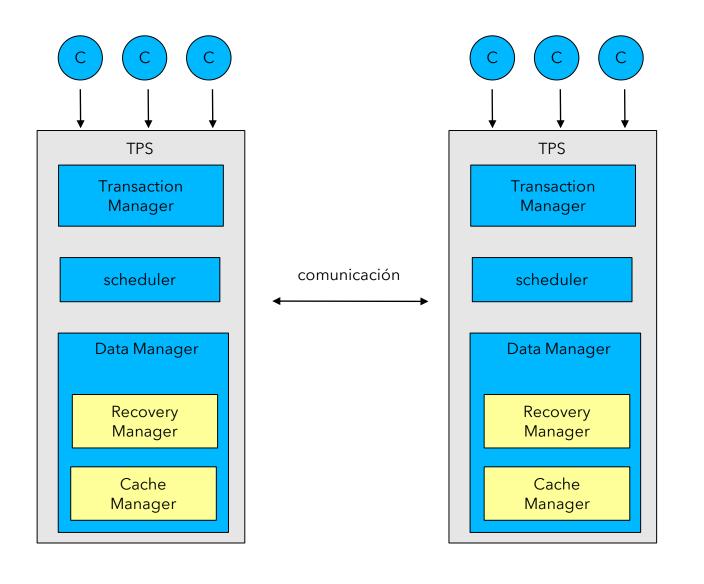
### TRANSACCIÓN DISTRIBUIDA ANIDADA



- Cuando una transacción distribuida termina, la propiedad de atomicidad exige que todos los servidores acuerden lo mismo (commit) o todos aborten (abort). Existen protocolos para llegar a compromisos (Two-Phase-Commit y Three-Phase\_Commit)
- Las transacciones distribuidas deben ser globalmente serializadas. Existen protocolos de **control de concurrencia distribuida**.

### TRANSACCIONES DISTRIBUIDAS

### PROCESAMIENTO DE TRANSACCIONES DISTRIBUIDAS



TPS: Transaction Processing System

- Un cliente inicia una transacción (begin\_transaction) sobre un TPS. El Transaction Manager identifica y localiza los objetos invocados por la transacción.
- Las invocaciones a los objetos locales son pasados al *Scheduler* local, las invocaciones a objetos remotos son pasados a TPS remotos correspondientes.

#### Observaciones:

- Un cliente inicia una transacción (begin\_transaction) en un único nodo ==> Nodo coordinador.
- Un objeto reside en único nodo (no hay replicación de objetos). La invocación de tal objeto toma lugar en ese nodo.

# PROCESAMIENTO DE TRANSACCIONES DISTRIBUIDAS

# PROCESAMIENTO DE TRANSACCIONES DISTRIBUIDAS

- . Observaciones (cont.):
  - Existen mecanismos para localizar un objeto, dado su identificador único.
  - Las instancias de TPS deben cooperar
- · Coordinador de una transacción distribuida
  - Un cliente comienza una transacción enviando un begin\_transaction a cualquier servidor TPS. Éste se convierte en el coordinador y los que se tengan que contactar a partir de aquí se convierten en trabajadores.

# PROCESAMIENTO DE TRANSACCIONES DISTRIBUIDAS

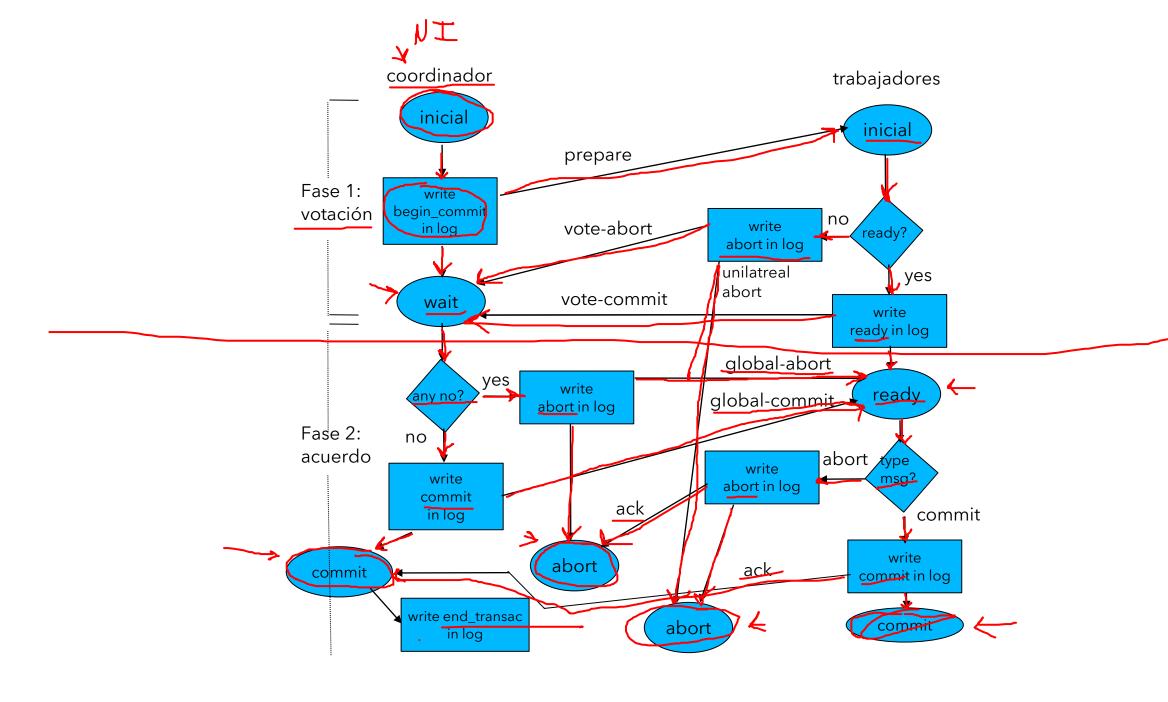
- Coordinador de una transacción distribuida (cont.)
  - · Para esto se requieren otras primitivas:
    - AddServer (tid, server\_id del coordinador):
    - Es enviado por el coordinador a otro servidor informándole que está envuelto en la transacción *tid*.
    - NewServer(tid, server\_id del trabajador):
  - Es la respuesta ante un *AddServer* de un trbajador al coordinador. El coordinador lo registra en su lista de trabajadores.

- Cuando el coordinador recibe un requerimiento *Commit* de una transación, tiene que asegurar:
  - . Atomicidad: Todos los nodos se comprometen con los cambios o ninguno lo hace y cualquier otra transacción percibe los cambios en todos los nodos o en ninguno.
  - Aislamiento: Los efectos de la transacción no son visibles hasta que todos los nodos —
     hayan tomado la decisión irrevocable commit o abort.

### ALGORITMOS DE COMPROMISO

## ALGORITMOS DE COMPROMISO

- El protocolo Two-Phase Commit (TPC):
  - Durante el progreso de una transacción no hay comunicación entre el coordinador y los trabajadores, solo con *AddServer* y *NewServer*.
  - El requerimiento commit o abort del cliente, llega al coordinador.
  - Si es *abort*, el coordinador se lo informa inmediatamente a todos los trabajadores.
  - . Si es commit, se aplica el protocolo TPC.

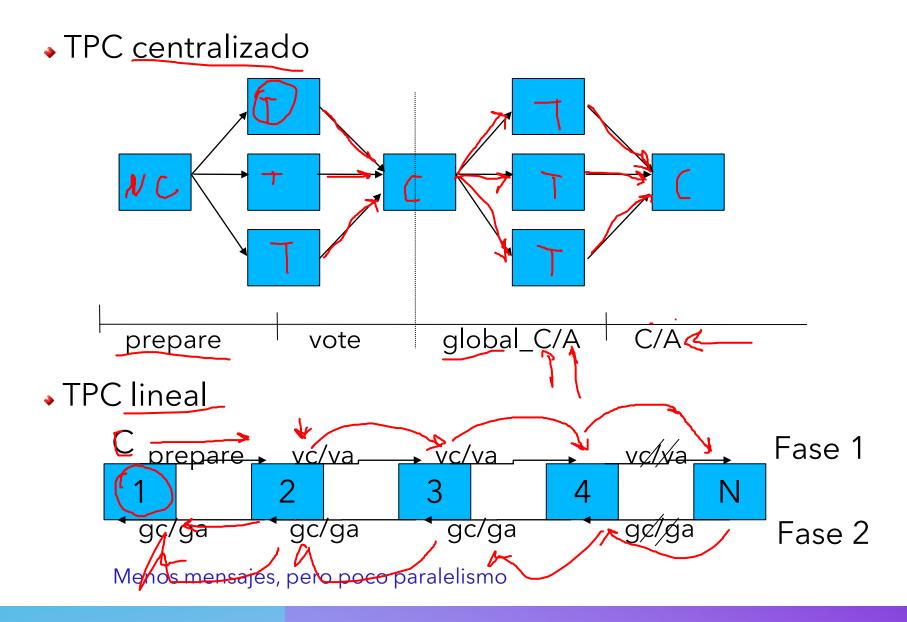


# ALGORITMOS DE COMPROMISO

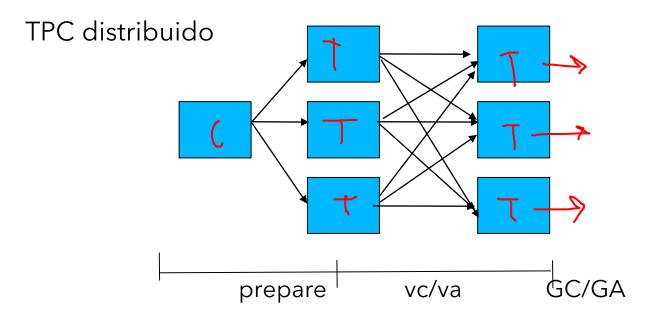
¿Cuáles serán las acciones del protocolo TPC ante timeouts?

- · Timers en los estados del coordinador: Wait, Commit o Abort.
  - <u>Timeout en el estado Wait:</u> Decide abortar la transacción, lo escribe en el log y envía el mensaje global\_abort a los trabajadores.
  - Timeout en los estados <u>commit</u> o <u>abort</u>: Envía el mensaje <u>global commit</u> o <u>global\_abort</u> respectivamente a los trabajadores que aún no han respondido y espera por sus ack.
- Timers en los estados de los <u>trabajadores</u>: *Inicial o Ready*.
  - Timeout en el estado *Inicial*: Decide abortar unilatealmente. Si el mensaje *prepare* llega después, el trabajador puede enviar un <u>vote abort</u> o ignorarlo.
  - · <u>Timeout en el estado Ready</u>: Se debe quedar bloqueado esperando alguna noticia

### PARADIGMAS DE COMUNICACIÓN PARA EL TPC



# PARADIGMAS DE COMUNICACIÓN PARA EL TPC



- El GC/GA es una decisión de cada participante de acuerdo a los votos recibidos
- Se elimina la fase 2
- Lineal y distribuidos requieren conocer los lds de todos los participantes.

# CONTROL DE CONCURRENCIA

- La idea es resolver las operaciones conflictivas
- Operaciones conflictivas: 2 operaciones son conflictivas cuando sus efectos combinados dependen del orden en el cual fueron ejecutadas.
- Para dos transacciones A y B, se consideran conflictivas las siguientes operaciones:
- . A B
- · read read no conflictivas
- · read write conflictivas
- write write conflictivas
- Cuando dos o más transacciones son conflictivas es necesario su serialización para asegurar la consistencia de los datos después de su ejecución.

### **CONTROL DE CONCURRENCIA**

- Las Operaciones conflictivas derivan en dos problemas:
  - Actualizaciones perdidas

Transacción T	Transacción U
balance=b.getBalance()	balance=b.getBalance()
b.setBalance(balance*1.1)	b.setBalance(balance*1.1)

```
Ejecución
T U
balance=200$
balance=220$
balance=220$
(balance debió ser 200+20+ 22)
```

Recuperaciones inconsistentes

# Transacción V Transacción W a.retirar(100) unasucursal.totalSucursal(a,b) b.deposita(100))

Ambos problemas se resuelven definiendo Equivalencia Secuencial ==> Control de concurrencia

## **CONTROL DE CONCURRENCIA**

 Las transacciones pueden abortar, ante esta situación surgen otros problemas: lecturas sucias y escrituras prematuras

Lecturas Sucias

Transacción T Transacción U

a.getBalance()(100\$)

a.depositar(10) (110\$)

a.getBalance() (110\$)

a.deposita(20) (130\$)

commit

aborta

U tomó el valor 110\$ que ahora no es válido.

- La estrategia para la recuperación es retrasar la acción de commit de U hasta que T finalice
- Esto conlleva a la posibilidad de **Abortos en Cascada** (si T aborta, U debe abortar también)

# Escrituras prematuras (perdida de actualizaciones)

•

- La estrategia para la recuperación es retrasar los writes hasta el momento del commit
- Para evitar ambos problemas se debe proveer ejecución estricta de las transacciones (propiedad de aislamiento)

# CONTROL DE CONCURRENCIA

# ALGORITMO DE LOCKING O BLOQUEO

- Nivel de granularidad del bloqueo: tiene que ver con el tamaño del objeto o dato que se está bloqueando
- A mayor granularidad (mayor fineza del grano), más pequeño es el tamaño del objeto.
- El nivel del bloqueo es directamente proporcional al grado de paralelismo y concurrencia, pero también es directamente proporcional al grado de complejidad de los sistemas
- Mientras mayor sea la fineza del grano, mejor será el grado de paralelismo/concurrencia, pero mayor será la complejidad del sistema.
- El bloqueo puede ser a nivel de item, página, archivo, base de datos (donde item representa el grano más fino y base de datos corresponde al grano más grueso)

- Consiste en que cada vez que un proceso necesita leer o escribir en un objeto como parte de una transacción, el objeto se bloquea hasta que la transacción culmine exitosamente (commit) y cualquier otra transacción que desee hacer alguna operación sobre dicho objeto tendrá que esperar hasta que él sea desbloqueado.
- Los locks son adquiridos y liberados por el administrador de transacciones, esto implica que todo lo concerniente al control de concurrencia es transparente para el programador.
- El administrador de *locks* puede ser centralizado o local para cada máquina

### ALGORITMO DE LOCKING O BLOQUEO

### ALGORITMO DE *LOCKING* O BLOQUEO

lock otorgado lock solicitado

Ninguno read OK - write OK

read OK - write Espera

write read Espera - write Espera

- <u>Una mejora</u>: utilizar *locks* de escritura y *locks* de lectura para ofrecer un mejor paralelismo al permitir que se realicen concurrentemente transacciones que hagan operaciones no conflictivas.
- Otra mejora: promoción de *locks*, si varias transacciones necesitan un objeto para lectura y luego para escritura, se les puede otorgar un *lock* de lectura hasta que alguna necesite escribir en el objeto. Se le otorgará el *lock* de escritura después de que todas las demás transacciones que tengan *locks* de lectura sobre el mismo objeto, lo liberen. La ventaja de esta mejora es que provee un mayor grado de paralelismo.

# ALGORITMO DE LOCKING O BLOQUEO

- · Resuelve "recuperaciones inconsistentes"
  - No hay posibilidad de que dos operaciones conflictivas se ejecuten concurrentemente
- Resuelve "pérdida de actualizaciones"
  - Si dos transacciones leen el mismo dato y luego lo modifican, la 2da. espera (ya sea por promoción o por no otorgamiento)
- El problema del algoritmo de *locking* es que puede ocasionar *deadlocks* y abortos en cascada, por lo que se han propuesto algunas variaciones para evitar tales problema.

# ALGORITMO DE LOCKING O BLOQUEO

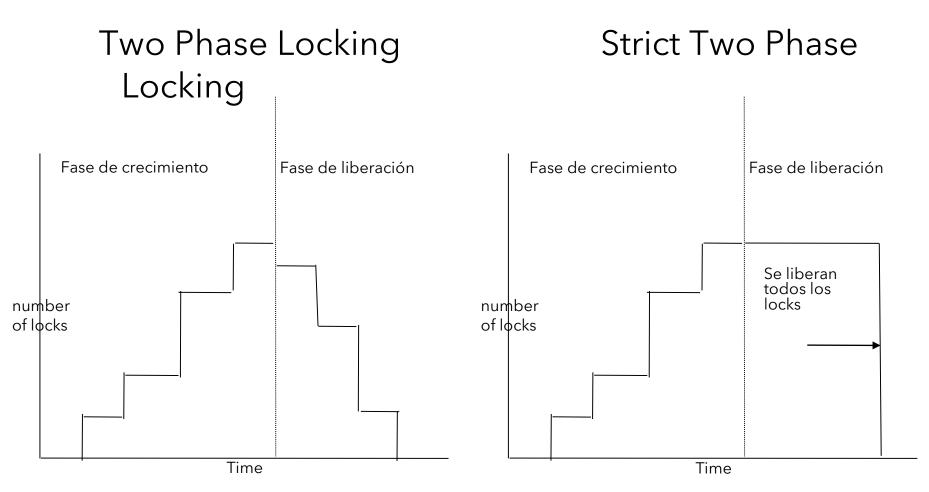
- Two Phase Locking: "obtención" y "liberación"
  - Durante la fase de "obtención", la transacción trata de obtener <u>todos</u> los *locks* que necesite. Si no es posible obtener alguno, entonces espera.
  - La segunda fase comienza cuando la transacción libera alguno de los *locks*, a partir de ese momento no podrá solicitar ningún otro *lock* (si lo hace, será abortada).
  - Desventaja: si una transacción en la fase de liberación había desbloqueado algunos objetos y los mismos habían sido accedidos por otras transacciones antes de que la primera hiciera commit, entonces las demás transacciones deberían abortar (esto es abortos en cascada).

# ALGORITMO DE LOCKING O BLOQUEO

#### Strict Two Phase Locking:

- La fase de "liberación" se realiza sólo cuando la transacción hace commit
- La mejora: evita los abortos en cascada
- Desventajas:
  - . El nivel de paralelismo se degrada
  - · Permanece la posibilidad de *deadlock*
  - . Aún representa un alto costo de mantenimiento

## Algoritmo de locking o bloqueo



- Se basa en las siguientes premisas:
  - · "Los conflictos suceden poco"
  - · "Como vaya viniendo vamos viendo"
  - · "¡Adelante!, haz lo que quieras sin atender lo que los otros hacen, no te preocupes por los problemas ahora, preocúpate más tarde"
- Las modificaciones/accesos se hacen sobre **espacios privados** y se lleva registro de los datos que han sido modificados/accedidos. Al momento del commit, se chequea que los espacios privados sean válidos, de no serlos, se aborta la transacción.
- . A toda transacción se le asigna un identificador (orden secuencial ascendente) para llevar una sucesión de transacciones en el tiempo.

- Cada transacción cumple tres fases:
  - <u>Trabajo:</u>Todos los reads se ejecutan inmediatamente sobre la última versión "comprometida" del dato. Los writes crean versiones tentativas. Se mantiene un conjunto de lectura (datos leídos) y un conjunto de escritura (versiones tentativas de los datos).
    - No hay posibilidad de "lecturas sucias", ¿por qué?
  - · <u>Validación</u>: Ante la solicitud de un commit, se valida si la transacción realizó operaciones conflictivas con otras transacciones.
  - <u>Escritura</u>: Si la transacción es validada, todos los cambios hechos sobre los **espacios privados** son actualizados en las versiones originales.

#### Fase de validación:

- · Ante el close\_transaction, a cada transacción se le asigna un número (secuencial ascendente, i) que define su posición en el tiempo.
- La validación se basa en las siguientes reglas (i < j):
- · <u>Ti Tj Regla</u>
- · read write Ti no debe leer datos escritos por Tj
- · write read Tj no debe leer datos escritos por Ti
- · write write Ti no debe escribir datos escritos por Tj y
- Tj no debe escribir datos escritos por Ti
- Simplificación: fases de validación y escritura son secciones críticas, entonces se satisface la regla 3. Sólo hay que validar las reglas 1 y 2

#### Validación hacia atrás:

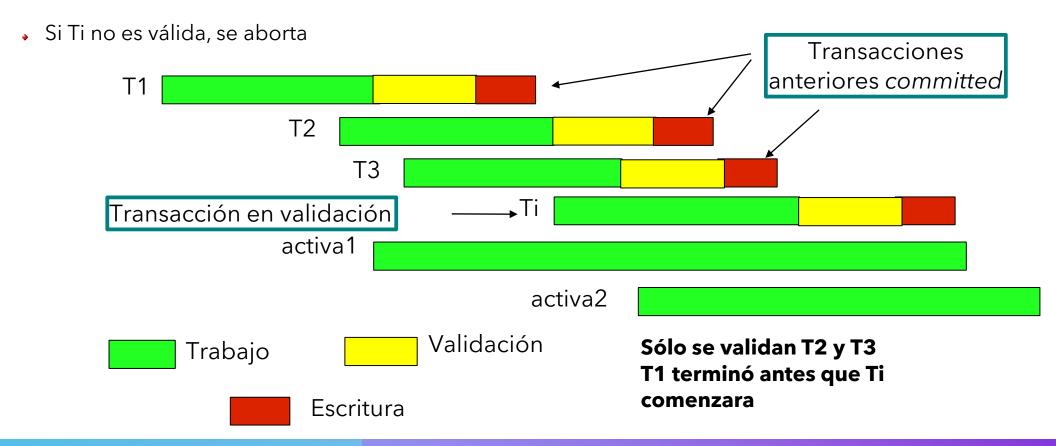
- Los reads de las Tj se realizaron antes que la validación de Ti, entonces se cumple la regla 1.
- · Sólo se valida la regla 2 para cada Tj:

```
valid= true;
for (Tj=startTn+1;Tj<=finishTn,Tj++) {</li>
if ("read_set" of Ti intersects "write_set" Tj)
valid=false;
}
```

- <u>startTn</u>: Tj más grande asignado a una transacción committed al momento que Ti entra a su fase de trabajo
- · <u>finishTn</u>: Tj más grande asignado al momento que Ti entra a su fase de validación

#### Validación hacia atrás:

• Sólo es necesario validar los conjuntos de lectura. Las transacciones que sólo hacen escritura no se validan.



#### Validación hacia delante:

- Se satisface la regla 2 porque las transacciones activas no escriben mientras que Ti no se ha completado.
- · Sólo se valida la regla 1 para cada Tid:

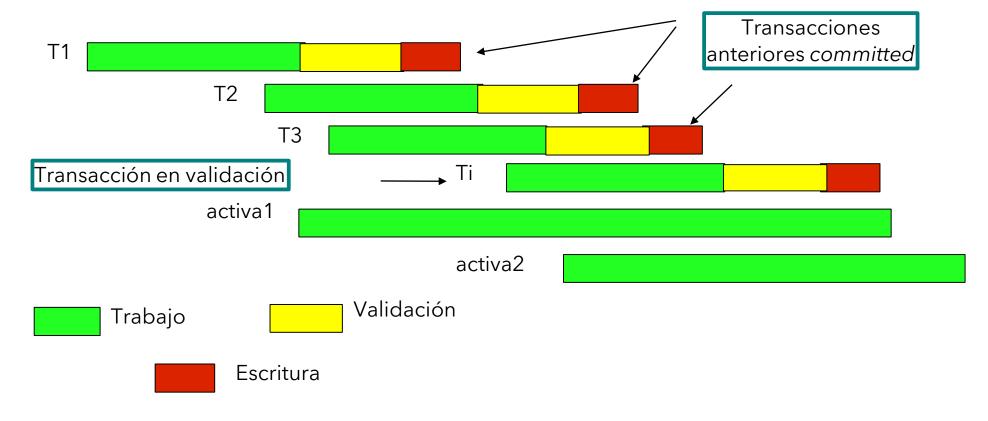
```
valid= true;
for (Tid=activa1;Tid<=activaN,Tid++){</li>
if ("write_set" of Ti intersects "read_set" Tid)
valid=false;
}
```

- · activaX: Representan transacciones que aún no han entrado a la fase de validación
- Las transacciones que sólo hacen lecturas no requieren ser validadas

#### Validación hacia adelante:

#### **ALGORITMO OPTIMISTA**

- Si Ti no es válida:
  - Aplazar la validación (¿le irá mejor en el futuro?)
  - Abortar las activas y consumar Ti
  - Abortar Ti (¿qué pasa si alguna de las futuras Tj es abortada?



#### **Desventajas:**

- . Hay posibilidad se inanición: una transacción puede abortar indefinidas veces y no se contempla mecanismo para evitar esto.
- También es importante saber que este algoritmo no serviría para nada en sistema con carga alta.
- Otra desventaja es que este algoritmo produce mucha sobrecarga porque hay que mantener los conjuntos de escritura de transacciones que ya terminaron (hacia atrás)

- Las operaciones se validan al momento de ser ejecutadas
- · Cuando una transacción comienza, se le asigna un timestamp
- Se trabaja con versiones tentativas
- Cada item de dato tiene asociado:
  - Un timestamp de escritura (Twrite\_commit), un timestamp de lectura (Tread) y un conjunto de versiones tentativas con su propio timestamp
- Un write aceptado genera una versión tentativa
- Un read se dirige a la versión con el máximo timestamp menor que el timestamp de la transacción

La validación se basa en las siguientes reglas:

```
Regla Tj Ti Condición

1 write read Tj no debe escribir un dato leído por Ti>Tj
(requiere que Tj >= max(Tread) del dato)

2 write write Tj no debe escribir un dato escrito por Ti>Tj

(requiere que Tj > max(Twrite_commit) del dato)

3 read write Tj no debe leer un dato escrito por Ti>Tj

(requiere que Tj > Twrite_commit)
```

Para saber cuando un write es válido, se aplica el siguiente algoritmo (validación de las reglas 1 y 2- regla de escritura):

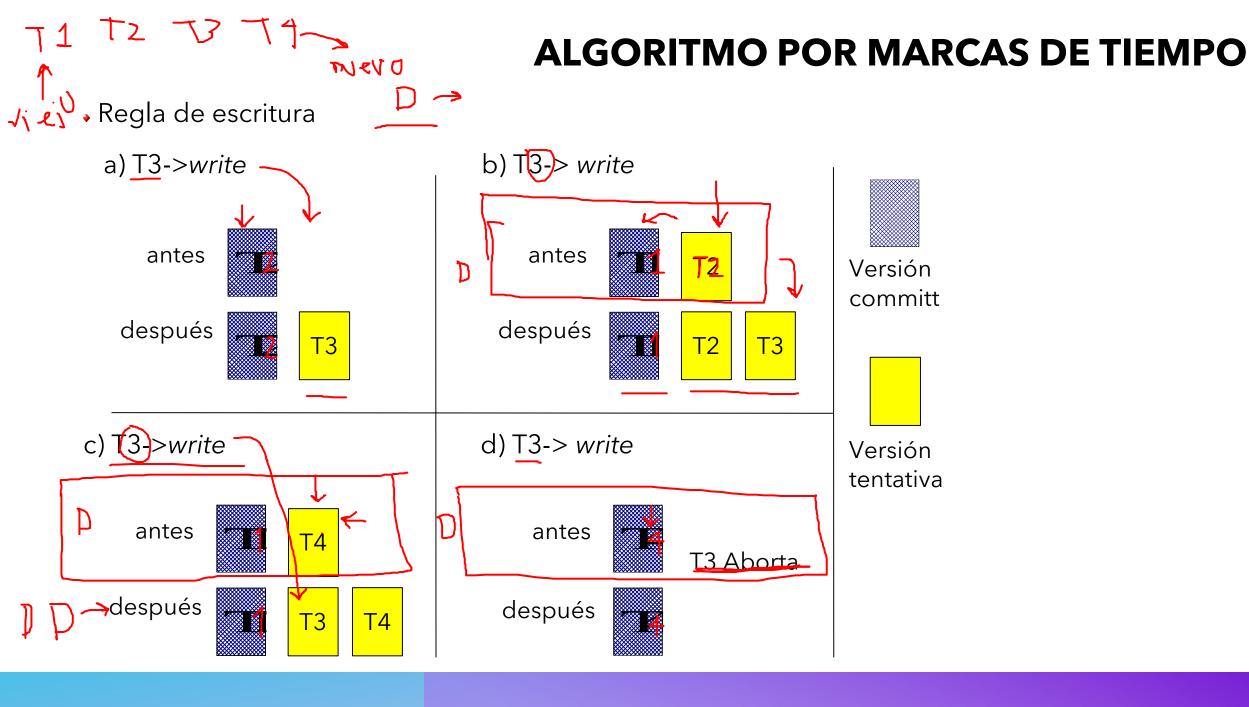
Sea Tj una transacción que desea hacer un write sobre el objeto D.

```
If ((Tj \ge Max (Tread en D)) && (Tj > write_commit en D))
```

Proceder con el write sobre una versión tentativa nueva;

else // write is too late

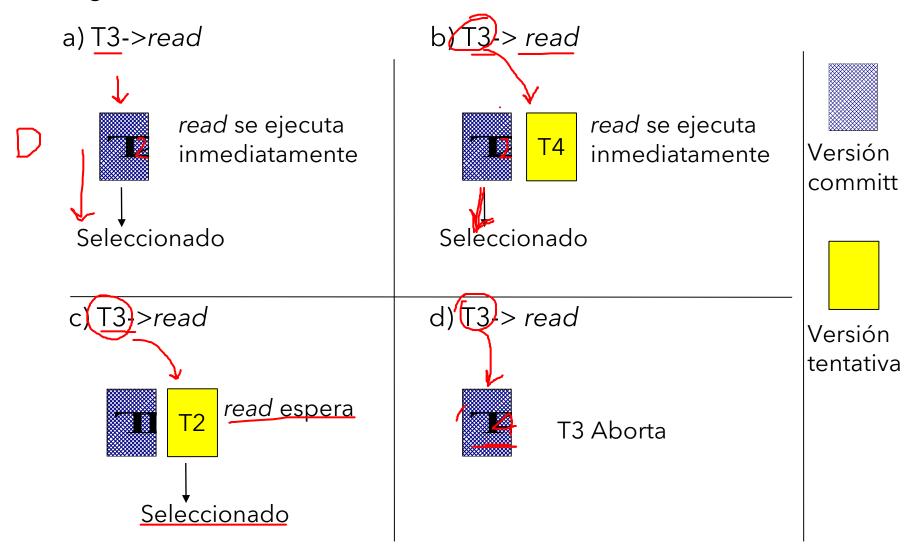
Abortar Tj;



```
Validación de la regla 3 (regla de lectura): Tj hace read(D)
  if (Tj > Twrite_commit en D) {
        Dselected with Max (Twrite <=Tj en D);
if (esCommit (Dselected)) {
         Procede el read sobre Dselected;
 } else {
            Esperar hasta que la <u>Ti que</u> hizo la versión
                                                              tentativa de Dselected haga commit o abort;
          volver a comenzar;
} else {
  Abortar Tj;
```

### Algoritmo por Marcas de Tiempo

• Regla de lectura



# TRATAMIENTO DE INTERBLOQUEOS

- . Condiciones para un bloqueo:
- 1.- Condición de <u>exclusión mutua.</u> Cada recurso está asignado a un único proceso o está disponible.
- 2.- Condición de posesión y espera Los procesos que tienen, en un momento dado, recursos asignados con anterioridad, pueden solicitar nuevos recursos.
- 3.- Condición de <u>no apropiación</u>. Los recursos otorgados con anterioridad no pueden ser forzados a dejar un proceso. El proceso que los posee debe liberarlos en forma explícita.
- 4.- Condición de <u>espera circular</u>. Debe existir una cadena circular de dos o más procesos, cada uno de los cuales espera un recurso poseído por el siguiente miembro de la cadena.

# TRATAMIENTO DE INTERBLOQUEOS

- · Políticas frente a los bloqueos:
  - . 1.- Ignorar:el tratamiento del deadlock es responsabilidad del programador y/o de las acciones.
  - 2.- Detectar:dejar que suceda y luego recuperarse.
  - 3.- Prevenir: Evitar que estructuralmente sea posible el deadlock, es decir, asegurar que al menos una de las cuatro condiciones no se cumpla.
  - 4.- Algoritmo del Banquero: Se necesita conocer los requerimientos de recursos del proceso. (No es aplicable en sistemas distribuidos por su complejidad de conocer los requerimientos de recursos de los procesos con anterioridad).

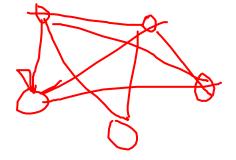
## TRATAMIENTO DE INTERBLOQUEOS

Se distinguen los siguientes tipos de Deadlocks:

1.- Deadlock de Comunicación:

A B C send(B) send(C) send(A) 
$$\leftarrow$$
 recv(C)  $\leftarrow$  recv(A) recv(B)

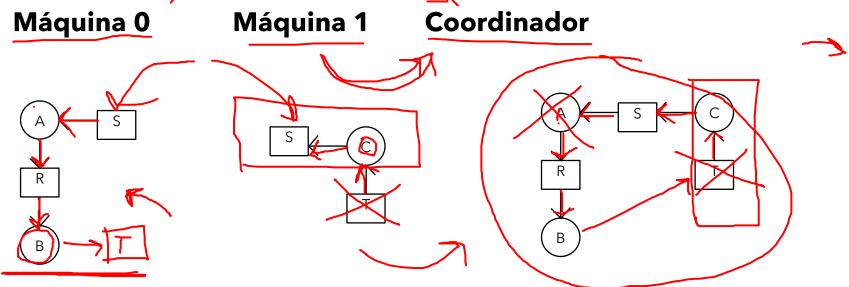




- Si el <u>send es b</u>loqueante entonces estamos en presencia de deadlock.
- Este tipo de deadlock es más frecuente en <u>Sistemas Paralelo</u>s, pues la filosofía de comunicación es de todos con todos, mientras que en el caso de sistemas distribuidos con la filosofía de <u>cliente-servidor</u>, es menos probable, aun cuando es posible.
  - 2.- Deadlock de Recursos: Es más frecuente en sistemas distribuidos.

## Algoritmos de Detección

1.- Centralizado: basado en grafos de espera



Cómo se mantiene el grafo en el coordinador?

- Cada vez que ocurra una variación en su grafo notifica al coordinador.
- Periodicamente cada máquina notifica sus últimos cambios.
- Periodicamente el coordinador solicita la información.

Problema: Los 3 casos pueden conducir a un Deadlock falso.

Ejemplo: Si se pierden mensajes

Si B solicita a T y C libera a T y llega primero el mensaje de B al coordinador, entonces el cree que hay deadlock.

## ALGORITMOS DE DETECCIÓN

- 2.- Distribuido: basado en grafo de recursos y procesos.
- Asuma comunicación confiable.
- A los procesos (o transacciones) se les permite pedir varios recursos a la vez.
  - Cuando un proceso tiene que esperar un recurso ocupado:
- 1.)Envía un mensaje "Prueba" al que tiene el recurso El mensaje consiste en:
  - .- Número del proceso que tiene que esperar.
  - .- Número del proceso que envía el mensaje.
  - .- Número del proceso que recibe el mensaje.
- 2 Cuando un proceso recibe un mensaje de Prueba Si él espera por otro recurso Si recibe (0,X,0) entonces hay Deadlock.
  - Recuperación: Eliminar una transacción, el proceso decide terminarse (Suicidio: puede inducir a suicidios colectivos innecesarios), seleccionar victima.
  - ¿Puede suceder deadlock falso?

## ALGORITMOS DE PREVENCIÓN

• Se basan en asignar a cada transacción un timestamp: Si una transacción requiere un recurso que otra transacción tiene se chequean los timestamp, y se toma una acción dependiendo de la política seleccionada.

